


Meeting 5

ECMNet: Lightweight Semantic Segmentation with Efficient CNN-Mamba Network

1. 文章试图解决什么核心问题？
 - a. 如何在保持高语义分割精度的同时，显著降低模型参数量与计算复杂度，使其适用于资源受限场景（如边缘设备/实时任务）。
2. 这是否是一个新问题？为什么会存在这个问题？
 - a. 不是全新问题，该论文首次将 Mamba 与 CNN 结合，引入轻量 attention 模块，对模型推理速度与精度进行双重优化：
 - i. Transformer 虽能处理长距离依赖，但复杂度高；
 - ii. CNN 本地建模能力强但缺乏全局视野；
 - iii. Mamba 模型提出后，首次实现线性复杂度的序列建模，具备处理高分辨率图像潜力；
3. 这篇文章要验证一个什么样的科学假设？
 - a. 融合 CNN 的局部建模能力与 Mamba 的线性长依赖建模机制，能在轻量级条件下显著提升语义分割的精度与效率。
4. 有哪些相关研究？如何归类？谁是该课题值得关注的研究员？
 - a. 传统轻量CNN：ESPNet, LEDNet, CFPNet
 - b. CNN + Transformer：HResFormer, PFormer, DMFC-UFormer
 - c. CNN + Mamba：SegMamba (3D), CM-UNet
5. 论文的解决方案关键是什么？各子模块解决了什么？



- a. EDAB (增强双分支注意力块)
 - i. 通道压缩: 输入 x 通过卷积初步特征抽取, $3 \times 1 \rightarrow 1 \times 3$ 模拟2D卷积, 可减少参数

$$F_{up} = \text{Conv}_{1 \times 3}(\text{Conv}_{3 \times 1}(\text{Conv}_{1 \times 1}(x)))$$
 - ii. Channel Attention分支: depthwise conv然后通道加权, 提取局部空间信息和通道信息

$$F_1^{\text{mid}} = \text{CA}(\text{Conv}_{1 \times 3, D}(\text{Conv}_{3 \times 1, D}(F_{up})))$$
 - iii. Dual-Direction Attention分支: 带膨胀率 R 的深度卷积, 增大感受野, 该分支关注**中长距离上下文关系** + 空间方向引导

$$F_2^{\text{mid}} = \text{DDA}(\text{Conv}_{1 \times 3, D, R}(\text{Conv}_{3 \times 1, D, R}(F_{up})))$$
 - iv. 所有路径特征融合 + 通道恢复 + 洗牌

$$Y_1 = \text{Shuffle}(\text{Conv}_{1 \times 1}(F_{up} + F_1^{\text{mid}} + F_2^{\text{mid}}) + x)$$
 - b. MSAU (多尺度注意力单元)
 - i. 作用于3个长距离跳连路径, 用于提升跳连特征的表达能力
 1. Multi-Scale Spatial Aggregation分支
 2. Channel Aggregation分支
 - c. FFM (融合模块, 含Mamba SS2D)
 - i. 使用 SS2D (Selective Scan 2D) 建模长距离依赖


$$\text{FFM}(x) = \underbrace{\text{FFN}(\text{SS2D}(\text{Concat}(x_{\text{encoder}}, x_{\text{MSAU1}}, x_{\text{MSAU2}})))}_{\text{Mamba-like sequence modeling}} + x_{\text{encoder}}$$
 - ii. Concat: 融合解码器输出和2个跳跃链接特征
 - iii. **SS2D: 提炼Mamba的核心, 用于状态空间扫描建模**
 - iv. FFN: 非线性特征变化, 强调关键语义信息
6. 和其他工作相比, 有哪些优化或创新点?
 - a. 首次在轻量级语义分割中系统引入Mamba模块 (SS2D) ;
 - b. 全卷积架构无全连接/位置编码, 便于部署;
 - c. 参数量仅 0.87M, 远低于其他 SOTA, 精度优于同类模型。
 7. 论文中的实验是如何设计的?
 - a. 指标: 参数(K)、FLOPs(G)、mIoU(%)。例如, C3 (完整ECMNet) 提升mIoU 3.7% over baseline
 - b. 消融实验:
 - i. 模块级验证 (EDAB、MSAU、FFM) , 分为三组 A/B/C 系列。
 8. 数据集和开源情况?
 - a. 数据集:
 - i. Cityscapes (分辨率高, 复杂交通场景) ;
 - ii. CamVid (小样本、11类)
 - b. 代码未开源
 9. 实验结果是否支持科学假设?
 - a. 是的:
 - i. 相比 LETNet (0.95M, mIoU 72.8%) , ECMNet (0.87M) 达到 73.6%
 - ii. 消融实验中, FFM (含Mamba) 模块单独带来 1.11% 提升;
 - iii. MSAU 模块仅增加 9K 参数, mIoU 提升 0.92%;

10. 本文的贡献总结

- a. 新架构ECMNet: 提出首个轻量级CNN-Mamba混合网络用于语义分割, 实现参数 (0.87M) 和精度 (70.6% mIoU) 的高效平衡
- b. 模块级创新:
 - i. EDAB: 轻量化双注意模块, 减少计算同时增强局部特征
 - ii. MSAU: 多尺度注意力单元, 提升跨层特征融合
 - iii. FFM: 基于Mamba的特征融合模块, 以线性复杂度优化全局上下文

11. 下一步有什么工作可以继续深入?

- a. 文章核心是, 用小的卷积, 代替普通卷积做特征抽取, FFM SS2D模块用于替代Transformer建立长距离依赖, 那可以拓展SS2D模块应用到医疗图像, 单纯应用到医疗图像缺乏创新, 则可以考虑以下:
 - i. SS3D (Selective Scan 3D) 模块到3D医疗图像
 - ii. **医疗的多模态融合**: 套用SSD思想, 用模态A引导模态B的注意力建模, 实现跨模态的gated特征融合
 1. 使用可学习的卷积核 + 门控机制 (Gating) 代替传统 self-attention
 2. 医学图像中的多个模态往往存在一定的互补关系
 3. 使用一个模态的 gating map (注意力), 作用于另一个模态的特征, 扮演状态 s_{t-1} 的角色




Ref:

1. Mamba是什么? 文中哪里使用了Mamba思想?
 - a. **Mamba** 是一种面向高效长序列建模的新兴状态空间模型
 - i. 线性复杂度
 - ii. 无需注意力建立长依赖
 - b. Mamba思想核心是:
 - i. 用状态空间建模的思想, 以线性复杂度建模长距离依赖与全局交互
 - c. 模型中的 **FFM (Feature Fusion Module)** 使用了 **SS2D block**, 即 **二维选择扫描机制**
$$\text{FFM}(x) = \underbrace{\text{FFN}(\text{SS2D}(\text{Concat}(x_{\text{encoder}}, x_{\text{MSAU1}}, x_{\text{MSAU2}})))}_{\text{Mamba-like sequence modeling}} + x_{\text{encoder}}$$
 - i. Concat: 融合解码器输出和2个跳跃链接特征
 - ii. **SS2D**: 提炼Mamba的核心, 用于状态空间扫描建模
 - iii. FFN: 非线性特征变化, 强调关键语义信息
2. SSD模块如何工作?
 - a. SS2D $\approx$ Mamba 中的 selective scan:

- i. 用可学习 kernel 进行空间扫描（卷积）；
 - ii. 实现“每个位置感受过去（深层）上下文状态”；
 - iii. 用门控机制（类似门控RNN）控制每步更新量。
- 3. EDAB之所以轻型，是因为用了小的卷积核？但是不同的卷积核提供了图像的不同特征？
 - a. 是的，同时卷积前做了通道压缩
 - i. 普通卷积 (1×1): 通道变换、升降维、融合通道信息->通道压缩/恢复
 - ii. Depthwise Conv ($3 \times 1, 1 \times 3$): 水平或垂直方向局部特征建模
 - iii. 带膨胀率的 depthwise conv: 稀疏卷积，扩展感受野不增加参数
 - iv. Atrous Conv (空洞卷积)：感受野增大但保持分辨率
 - b. EDAB的理论推理时间复杂度为 $O(H \times W \times C)$ ，远低于传统卷积模块的 $O(H \times W \times C^2)$

UnSegMedGAT: Unsupervised Medical Image Segmentation using Graph Attention Networks Clustering

1. 文章试图解决什么核心问题？
 - a. 解决**医疗图像分割中缺乏标注数据**的问题。
 - b. 它提出了一种无需人工标注数据的无监督分割方法，利用 Vision Transformer 和图注意力网络实现对医学图像的高质量分割。
2. 这是否是一个新问题？为什么会存在这个问题？
 - a. 这不是一个全新的问题
 - b. 医学标注需专业医生、耗时且涉及隐私
3. 这篇文章要验证一个什么样的科学假设？
 - a. 通过利用**预训练的视觉Transformer (DINO-ViT)** 提取图像特征，并结合**图注意力网络与模块化损失函数**进行图结构建模，可在无监督条件下实现与有监督模型相当甚至更优的医学图像分割效果。
4. 有哪些相关研究？如何归类？谁是这一课题在领域内值得关注的研究员？
 - a. 监督图像分割：如 U-Net, SegNet, DeepLab
 - b. 自监督 / 无监督图像分割：
 - i. ViT-KMeans、DSM、MinCutPool、DeepCut [10], GDISM [23]
 - c. 图神经网络结合视觉任务：
 - i. Graph Convolution Network (GCN)
 - ii. Graph Attention Network (GAT)
 - iii. Vision-GNN
 - iv. Graph clustering with GNN
5. 论文中提到的解决方案之关键是什么？各模块如何对应问题环节？



- a. DINO-ViT 预训练特征提取器：
 - i. 从图像中提取 patch-level 特征

$$A = f f^T \cdot \mathbb{I}(f f^T > \tau)$$

其中：

- $f f^T \in \mathbb{R}^{n \times n}$: 表示所有 patch 特征之间的相似性（注意：是未归一化的点积）。
- $\tau \in (0, 1)$: 是一个超参数阈值，控制“边”的保留。
- $\mathbb{I}(\cdot)$: 表示对每个点积值进行门控，只有高于阈值 τ 的连接才保留。

- b. 图构建与边筛选
 - i. 建立 patch 特征之间的连接关系，用**特征相似性决定邻接边结构**
 1. 用预训练好的DINO-ViT将图像划分成 $p \times p$ 的patch，总过 n 个
 2. 计算相似矩阵 S ，每个元素表示patch i 和patch j 的**点积相似度**，点积高的相似度就高，应该连接一条边
 3. 应用阈值 τ ，只有大于 τ 的边被保留，其他为0，**筛选出有用的边**

- a. 输出稀疏图结构
- c. 多头图注意力网络 (Multi-GAT)
 - i. 按注意力权重聚合邻居信息按注意力权重聚合邻居信息
- d. 双层全连接网络 (FCN)
 - i. 将图嵌入映射为聚类标签分布
- e. 模块化损失 + 正则项
 - i. 引导模型学习高质量聚类结构
- 6. 和其他相关工作相比, 有哪些优化? 或者有哪些创新点?
 - a. vs 传统GCN: GAT引入注意力机制, 替代GCN的等权邻域聚合
 - b. 模块化损失函数: 借助图社区划分思想, 无需标签即可引导聚类学习。
 - c. 轻量化模型设计: 适合数据有限、训练计算资源受限的场景。
- 7. 论文中的实验是如何设计的?
 - a. 实验对比方法包括:
 - i. 有监督: MedSAM
 - ii. 无监督: MinCutPool、DSM、GDISM、ViT-Kmeans、UnSegGNet
 - b. 指标: mIoU 和 Dice Score
 - i. 对比不同激活函数 (SiLU、ReLU、SeLU) 和不同模型变体 (UnSegMedGAT vs UnSegMedGATc)
- 8. 用于定量评估的数据集是什么? 代码有没有开源?
 - a. 数据集:
 - i. ISIC-2018: 结构复杂、边界模糊
 - CVC-ColonDB: 肠道息肉图像, 挑战在于目标小、对比低
 - b. 开源: <https://github.com/mudit-adityaja/UnSegMedGAT>
- 9. 论文中的实验及结果有没有很好地支持需要验证的科学假设?
 - a. 是的
 - i. 成功验证: 在ISIC-2018显著超越MedSAM, 证明无监督方法可克服监督模型的模态偏差。
 - ii. 局限性: 在ColonDB稍弱于MedSAM (因MedSAM训练含大量息肉数据), 但仍优于其他无监督方法。
- 10. 这篇论文到底有什么贡献?
 - a. 方法论创新: 首个结合ViT、GAT与模块化损失的无监督医学分割框架。
 - b. 性能突破: 在ISIC-2018超越MedSAM等监督模型, ColonDB达到SOTA无监督水平。
 - c. 轻量设计: 参数共享策略降低过拟合风险
- 11. 下一步有什么工作可以继续深入?
 - a. 没有什么特别有价值的想法

Ref

1. 原文是怎么利用图卷积GCN的? 边构建方法核心是什么?
 - a. 原文只是用了GCN的思想, 构建边, 其传播机制用了图注意力网络(GAT)
 - b. 边构建通过特征图点积, 增加阈值筛选出有用的边
2. 为什么点积, 即特征图乘上特征图转置, 就能得到相似度矩阵? 这种建边方法有什么问题吗?

- a. 点积衡量了两个向量在**方向上的相似度**，采用点积，计算高度并行，一步得到所有 patch-patch 相似度，不需要for-loop暴力算每2个patch

$$f_i \cdot f_j = \|f_i\| \cdot \|f_j\| \cdot \cos \theta$$

- i. 当cosine趋近于1，代表**向量方式几乎一致**
 - ii. 当cosine趋近于0，代表**向量方式正交，特征无关**
- b. 问题：
- i. 文中没有说相似度有没有归一化，如果没有归一化，会受特征范围影响，不能反映相似度
 - ii. 阈值 τ 难以选定阈值控制稀疏程度，但 τ 太高图会过稀， τ 太低又会引入噪声边

3. 建好相似图之后，多头注意力的机制是怎样的？怎么提取长依赖信息？

- a. GAT 在于：**对每个邻居分配不同“重要性权重”**，而不是像传统 GCN 那样一视同仁平均处理。
- b. 图注意力机制计算邻居 j 对 i 的注意力权重为：

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(a^\top [Wh_i || Wh_j]))}{\sum_{k \in \mathcal{N}(i)} \exp(\text{LeakyReLU}(a^\top [Wh_i || Wh_k]))}$$

单头注意力为：


$$h'_i = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} Wh_j \right)$$

多头注意力：在特征空间中用多个“通道”并行地计算注意力，**每个头都有独立的特征投影 + 聚合方式** (独立的W输入投影+独立的注意力大分a)

$$h'_i = \parallel_{z=1}^Z \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij}^{(z)} W^{(z)} h_j \right)$$

LiteNeXt: A Novel Lightweight ConvMixer-based Model with Self-embedding Representation Parallel for Medical Image Segmentation


1. 文章试图解决什么核心问题？
 - a. 模型轻量化与效率：现有Transformer架构（如TransUNet）参数量大、计算成本高，难以部署到移动设备
 - b. 边界模糊问题：医学图像中器官/病变边界不清晰（如息肉边缘、微血管），传统损失函数（如Dice Loss）难以精准分割
 - c. 小数据训练困境：医学标注数据稀缺，模型易过拟合
2. 这是否是一个新问题？为什么会存在这个问题？
 - a. 不是全新问题
 - i. 医学图像数据标注代价高 → 预训练依赖受限
 - ii. 医疗实际场景常部署在低功耗设备（如边缘/移动设备） → 推理资源受限
3. 这篇文章要验证一个什么样的科学假设？
 - a. 通过**轻量化ConvMixer架构（LGEMixer）**结合**自嵌入表征并行（SeRP）**训练策略，可实现与大型模型相当的精度，同时通过**边缘权重损失（MWL）**显著提升边界分割质量。
4. 有哪些相关研究？如何归类？谁是该课题值得关注的研究员？
 - a. Transformer-based: TransUNet, SwinUnet
 - b. Mixer架构 / 全MLP结构: MLP-Mixer, ConvMixer
 - c. CNN轻量结构: U-Lite, UNeXt
 - d. 边界/不平衡损失: Weighted BCE, B-BCE, Focal Loss
 - e. 自监督学习: BYOL
5. 论文解决方案的关键是什么？子模块对应解决哪些问题？




- a. LGEMixer (Local + Far Mixer) Encoder:
 - i. LocalMixer: 对特征3x3 conv，然后归一化
 - ii. FarMixer: 对特征进行7x7 DWConv，扩大感受野，捕捉长距离关系
 - iii. 通道混合: 2者输出1x1 conv+归一化，将通道融合

iv. 下采样: maxpool将特征图采样一半


$$\begin{aligned}x_1 &= \text{GELU}(\text{LN}(\text{Conv}_{3 \times 3}(x))), \\x_2 &= \text{GELU}(\text{LN}(\text{DWConv}_{7 \times 7}(x_1))) + x_1, \\x_3 &= \text{GELU}(\text{LN}(\text{Conv}_{1 \times 1}(x_2 + x))), \\y &= \text{MaxPool}_{2 \times 2}(x_3),\end{aligned}$$



(a)



(b)



(c)

(d)

(e)

b. SeRP训练策略:

i. 双分支框架: 相同结构但权重不同

1. 主干网络: 增加旋转、水平/垂直翻转, 颜色抖动, 高斯模糊->多样化的特征
2. 目标网络: 仅增加几何翻转->稳定的参考嵌入

ii. 特征提取和投影

1. 将 I_s 和 I_w 输入主干和目标提取器, 得到特征图生成两个embedding

iii. SeRP 损失

$$L_{\text{SeRP}} = 1 - \frac{\langle e_m, e_t \rangle}{\max(\|e_m\| \cdot \|e_t\|, \epsilon)}$$

- c. **边缘权重损失 (MWL)**
 - i. 分3区域动态加权, 提升对**边界的感知** (Ref 3)
- 6. 与其他工作相比, 有哪些优化或创新点?
 - a. LGEMixer模块: 模仿 ConvMixer + ConvNeXt, 用不同 kernel 建立远/近依赖
 - b. 首次在 segmentation 中用SeRP训练机制
 - c. MWL三区域加权损失函数
 - d. GCF模块替代跳跃连接解码器
- 7. 论文中的实验是如何设计的?
 - a. 全流程端到端训练 (无预训练)
 - b. 实验分为以下内容:
 - i. 多数据集覆盖: 小样本、低对比、高分辨率、复杂边界
 - c. 消融实验:
 - i. LGEMixer vs ConvMixer vs ConvNeXt
 - ii. SeRP 有无对比
 - iii. MWL vs Focal/BCE/WBCE 等
 - iv. MWL权重与核大小影响
 - v. SeRP 中不同距离度量的影响 (Cosine 最好)
- 8. 数据集和代码开源情况
 - a. 数据集:
 - i. Bowl2018/GlaS/ISIC2018/Sunnybrook/Lung X-ray
 - b. 开源: <https://github.com/tranngocduvnvp/LiteNeXt>
- 9. 实验结果是否支持科学假设?
 - a. 非常充分支持
 - i. 轻量化验证: 0.71M参数 (比UNeXt↓51.7%), 0.42G FLOPs (表1)
 - ii. 精度表现:
 - 1. Bowl2018上Dice 92.5%
 - 2. PH2数据集IoU 90.98%
 - iii. 边界优化: MWL使HD95降低27%
- 10. 这篇论文到底有什么贡献?
 - a. 提出了一个轻量但高效的医学图像分割模型 LiteNeXt (仅 0.71M 参数), 无需预训练
 - b. LGEMixer Block: 结合 Local 和 Far mixing 机制, 用于提取多尺度特征
 - c. Marginal Weight Loss: 边界感知损失, 提升分割细节与鲁棒性
 - d. 首次提出 SeRP 机制应用于监督分割任务中, 实现“边训练边增强”
- 11. 下一步有什么工作可以继续深入?
 - a. 优化**边缘权重损失**函数, 原文用的MWL, 比如Soft Distance Mask, 详见 Ref 4-6, 但是单单一个点不够创新, 文章的边缘权重损失思想可以带到其他模型训练


Ref:

- 1. 为什么 LGEMixer 能替代 Transformer 和传统卷积?
 - a. 本质是用3x3 conv做特征提取, 7x7 DWConv长距离建模, 可以作为Transformer 轻量级平替
- 2. SeRP究竟在解决什么问题? 为什么要有2个分支?
 - a. 训练的稳定性, 有自监督对比, 类似有一个老师一个学生

3. 为什么要在分支中注入增加旋转、水平/垂直翻转，颜色抖动，高斯模糊等？
 - a. 经典自监督方法，为了**引导模型学会跨视角、跨感知条件下的稳定特征表达**，从而提升模型泛化能力
4. 边缘权重损失 (MWL)，作者为什么这样做？究竟在解决什么问题？
 - a. 作者观察到，在医学图像中，**最容易出错的不是物体本身，而是边界**
 - i. 边界模糊
 - ii. 多个物体靠近
 - iii. 普通损失函数平均看待每个像素
 - b. 因此，作者对图像分成3类
 - i. 背景像素：无所谓，权重小
 - ii. 目标内部：权重中等
 - iii. 目标边界：权重大
 - c. 模型在训练时，遇到权重大的边界，会受到更大的惩罚(loss更大)，因此会努力把边界学习清楚，**分割本质上就是一个寻找边界的问题**
5. 作者是怎么把输入分成3类的？
 - a. 针对输入**group truth**来构建3类区域的**权重掩码 (GT Mask)**
 - i. 直接用 ground truth 来定义“哪里是边界”更简单、稳定、可控
 - ii. 保证了 MWL 是一个**无监督“结构先验增强”模块**
 - b. 2个经典形态操作：
 - i. 腐蚀 Erosion + 膨胀 Dilation
 - ii. **边界 = 膨胀区域 - 腐蚀区域**
 - iii. **背景 = 图像全集 - 膨胀区域**
 - iv. **物体 = 腐蚀区域**
6. 这种GT Mask分类方式有没有什么问题？能保证准确吗？
 - a. 我认为：MWL 属于一种“**先验增强**”机制，完全依赖 ground truth 的边界划分，**如果你一开始就用不准确的 Ground Truth 去引导模型“关注边界”，那模型学到的关注点就会是错误的。**
 - b. 可以考虑的策略：(虽然计算量增大，但是只需要做一次计算ground truth)
 - i. 原MWL： binary GT mask -> 膨胀/腐蚀 -> 划分区域 -> 固定权重 -> 3值权重图 -> 加权loss
 - ii. **Soft Distance Mask**: binary GT mask -> 提取边界 -> 计算每个像素到最近边界距离 -> 高斯函数生成权重 -> 连续值权重 -> 加权loss

G-CASCADE: Efficient Cascaded Graph Convolutional Decoding for 2D Medical Image Segmentation

- 文章试图解决什么核心问题？
 - 医学图像分割解码器的双重瓶颈：
 - 长距离依赖丢失：CNN-based
 - Transformer不善于捕捉局部特征，同时计算效率低下
- 这是否是一个新问题？为什么会存在这个问题？
 - 不是全新问题，问题根源
 - Transformer内在局限性
 - CNN内在局限性
 - 医学图像分割任务常常对**边界定位精度**要求极高
- 这篇文章要验证一个什么样的科学假设？
 - 将**图卷积网络 (GCN)** 与**空间注意力机制**结合，可以构建一个既高效又具有长距离建模能力的解码器
- 有哪些相关研究？如何归类？谁是该课题值得关注的研究者？
 - Vision Transformer：
 - ViT [Dosovitskiy, 2020]
 - Swin Transformer [Liu et al., 2021]
 - PVT/PVTv2 [Wang et al., 2021/2022]
 - MaxViT [Tu et al., 2022]
 - 图卷积网络 (GCN)：
 - Vision GNN (ViG) [Han et al., 2022]
 - 医学图像分割架构：
 - UNet/UNet++/UNet3+/DC-UNet
 - TransUNet [Chen et al., 2021]
 - Swin-Unet, MISSFormer, PolypPVT
 - CASCADE [Rahman et al., 2023]
 - MERIT [Rahman et al., 2023]
- 论文中的解决方案之关键是什么？子模块如何对应关键点？
 - 方案关键：**G-CASCADE解码器**，融合**图卷积与空间注意力机制**



- b. GCAM: 先做图卷积, 然后再做空间注意力进一步强化特征: 突出重要位置, 或抑制不重要位置

$$\text{GCAM}(x) = \text{SPA}(\text{GCB}(x))$$

- i. GCB图卷积模块: 取代3x3卷积建立长距离依赖
- ii. SPA空间注意力: 局部特征感知能力
 - 1. SPA的具体操作包括: (x为特征图输入)
 - a. Cmax: 沿通道维度做逐像素的最大值池化, 输出形状为: (B, 1, H, W), 代表每个空间位置的**最显著通道特征**
 - b. Cavg: 对输入特征图沿通道维度做逐像素的平均值池化, 输出形状为: (B, 1, H, W), 代表每个空间位置的**平均通道特征**
 - c. 上面两个特征拼接(concatenate)起来, 得到: (B, 2, H, W)
 - d. 7x7 conv + sigmoid

$$\text{SPA}(x) = \text{Sigmoid}(\text{Conv}([C_{\max}(x), C_{\text{avg}}(x)])) \otimes x$$

- iii. Up-Conv Block: depth-wise高效上采样卷积
 - iv. SegHead: 1x1卷积多尺度预测聚合
6. 相比其他工作, 有哪些优化或创新点?
- a. 首次将图卷积网络引入到Transformer解码器结构中, 提出GCAM模块。
 - b. 提出轻量化UCB模块, 替代传统上采样卷积操作, 极大减少参数。
7. 论文中的实验是如何设计的?
- a. 消融实验:
 - i. 子结构有效性 (表3): GCB+SPA组合提升DICE 3.2%。
 - ii. 结构顺序 (表4): GCB→SPA优于SPA→GCB (DICE 83.28% vs. 82.93%)。
8. 用于定量评估的数据集是什么? 代码有没有开源?
- a. 数据集:
 - i. Synapse Multi-organ (腹部CT)
 - ii. ACDC (心脏MRI)
 - iii. ISIC2018 (皮肤病变)
 - iv. Polyp (Endoscene, CVC-ClinicDB, Kvasir, ColonDB)
 - v. Retinal Vessel (补充材料)
 - b. 开源: <https://github.com/SLDGroup/G-CASCADE>
9. 实验及结果是否支持科学假设?
- a. 充分支持
 - i. 与多个SOTA方法比较中, DICE score全面提升
 - ii. 精度提升的同时, 模型复杂度显著下降
 - iii. 消融实验明确说明: 图卷积与空间注意力共同作用至关重要
10. 这篇论文到底有什么贡献?
- a. 首提图卷积解码器: G-CASCADE首次将图卷积用于医学图像分割解码, 解决长距离依赖丢失问题
 - b. GCAM模块创新: 整合图卷积 (GCB) 与空间注意力 (SPA), 全局-局部特征协同优化
11. 下一步有什么工作可以继续深入?

- a. 考虑优化GCN优化**边构建**的方法：
 - i. **局部注意力图(LAG)**, 但是已经有1-2篇讨论这个的文章，单个创新点可能不够 (e.g. UnSegMedGAT) 详细见 Ref 1-3
 1. **Update**: UnSegMedGAT用的**点积注意力**，还可以考虑：
 - a. 余弦相似度 - 点积归一化后
 - b. MLP
 - c. 高斯核
 - b. 考虑进一步优化SPA：SPA依然用单通道的7x7的卷积，对高分辨率图片依然计算量很大，可以进一步考虑是否不做卷积：
 - i. **Coordinate Attention (CA)**: 将 attention 分别沿**高度和宽度方向聚合**，保持空间位置信息，全部用1D卷积 (Conv1D)实现 Ref 4
 - c. 考虑结合上面2点，同时得找到**比较特殊的数据集**，或者对不同种类数据集实验，证明改进有效，比如高分辨率，小样板训练，跨模态数据，多器官，对比度低，对称结构，才能证明现有模型不足

Ref:

1. 什么是图卷积？和一般卷积有什么不同？
 - a. GNN：一种在**非欧几里得空间**上提取特征的方法，在图结构中，每个节点代表一个元素（如图像中的一个像素块），**边代表节点之间的关系（如相似性、距离、空间邻接等）**，图卷积通过聚合一个节点邻居的信息
 - i. 非欧几里德空间：没有固定坐标系，邻接关系是任意的，关系用邻接矩阵A或者KNN定义，

$$h_i^{(l+1)} = \sigma \left(\sum_{j \in \mathcal{N}(i)} W h_j^{(l)} \right)$$
2. 为什么图卷积能构建长距离依赖？和Transformer构建长距离依赖机制有什么异同？
 - a. 因为GNN特性，邻接关系不再是物理距离，而是语义相关性，可以跳跃空间
 - b. 图卷积 vs Transformer

维度	Transformer（自注意力）	图卷积（GNN）
依赖构建原理	显式计算所有位置对的相似度	基于拓扑结构的隐式关系推理
依赖传播机制	一步全局交互 token-to token	层级传播，每次只能看到相邻层
计算单元	像素/图像块（Patch）	语义节点（图像区域）
连接方式	全连接（所有位置对交互）	稀疏连接（K近邻动态构图）

位置感知	需显式位置编码 (Position Encoding)	通过相对位置向量自然嵌入
复杂度	$O(n^2)$	$O(nk)$ (k为邻居数, $k \ll n$)

3. 文章中的GNN邻边关系是怎么构建的? 为什么? 有没有更好的建模方法?

a. 基于**特征空间**(feature map)的 KNN构建方式:

- i. 和Transformer类似切成许多patch, patch成为KNN图的节点(node), edge由patch和patch之间的**相似度(L2距离决定)**
- ii. 计算所有节点对之间特征图的欧式距离, 选取Top K个距离最近的节点, 就得到一个dense KNN图

b. **L2边构建方法局限性:**

- i. 没有空间位置: e.g. 左肾和右肾虽然特征相似, 但是不相邻, 导致边界模糊错误识别等 -> 多器官的分割, 左右镜像结构等
- ii. 静态构建: 每轮向前传播, 边都不更新, 可能不适应语义变化, 模型不稳定 -> 引入稳定指标, 小样本训练, 跨模态数据
- iii. 特征尺度不敏感: 特征被标准化计算了, 某些通道的值分布偏大, 会主导距离计算, 小目标信息容易被主通道信息压制 -> 图像对比低
- iv. 没有方向和权重: 上下文不精准, 边界不清 -> 模糊边界器官, 长条结构

c. 其他构建方法:

i. 特征+空间混合距离构图 (Weighted Hybrid Distance Graph)

$$d_{ij} = \lambda \|x_i - x_j\|_2 + (1 - \lambda) \|p_i - p_j\|_2$$

ii. **局部注意力图 (Locally Attentive Graph)**

1. 仅在局部K邻居内, 用轻量注意力 (dot product或MLP) 建边权:

$$\alpha_{ij} = \text{softmax}_j \left(\frac{x_i^\top x_j}{\sqrt{d}} \right), \quad \text{where } j \in \mathcal{N}_K(i)$$

4. 文中的SPA为什么叫空间注意力? 并没有像Transformer有QKV注意力相关操作呢?

a. 属于广义的注意力机制:


- i. 动态地为输入信号分配权重, 增强重要部分, 减弱非重要部分, **选择性关注**: SPA有对特征图的空间维度进行加权聚焦

5. 为什么作者选择GCN+SPA作用在decoder端?


- a. 文章使用PVTv2和MERIT两个编码器, 对特征抽取已经足够强
- b. 作者创新主要设计一个无缝插拔的decoder, 负责重构细节

H2Former: An Efficient Hierarchical Hybrid Transformer for Medical Image Segmentation

- 文章试图解决什么核心问题？
 - 医学图像分割的三大核心挑战：
 - 局部与全局建模失衡：CNN长距离依赖
 - Transformer的计算瓶颈
 - 多尺度特征融合缺失：现有方法忽略通道维度的多尺度关系
- 这是否是一个新问题？为什么会存在这个问题？
 - 不是，CNN本身模型的局限性和Transformer带来的计算量问题
- 这篇文章要验证一个什么样的科学假设？
 - 通过设计一个**层次化的混合Transformer结构(Hierarchical Hybrid Transformer)**,结合CNN的局部特征、多尺度通道注意力 (MSCA) 与Transformer的长程依赖，可以有效提升医学图像分割的性能，同时保持计算高效性。
- 有哪些相关研究？如何归类？谁是这一课题在领域内值得关注的研究员？
 - 纯CNN方法：UNet系列 (U-Net、Attention U-Net、UNet++)
 - 纯Transformer方法：Swin-UNet、nnFormer、MISSFormer
 - CNN-Transformer混合方法：TransUNet、LeViT-UNet、UTNet
- 论文中提到的解决方案之关键是什么？方法中的每个子模块对应解决了这个问题当中的哪一个环节或者什么关键点？



- 多尺度通道注意力 (MSCA) :
 - 在不同尺度捕获特征，通道注意力动态调整不同尺度特征权重，实现特征选择与融合




- b. Transformer块
 - i. 通过窗口自注意力自注意力机制捕获全局长程依赖
- c. 轻量解码器
 - i. 轻量解码器
6. 和其他相关工作相比，有哪些优化？或者有哪些创新点？
 - a. **层次化混合结构**：阶段内CNN+Transformer+MSCA三重融合
 - b. 提出**多尺度通道注意力(MSCA)**，实现更精细的尺度特征选择与融合，非单一尺度的特征处理。
 - c. 计算效率：窗口注意力+降维策略
7. 论文中的实验是如何设计的？
 - a. 评估指标：Dice、IoU、准确率、MAE评估指标：Dice、IoU、准确率、MAE
 - b. 消融实验：
 - i. 验证了每个模块（CNN, Transformer, MSCA）的有效性
 - ii. 层次化混合结构相较于级联结构的优越性
8. 用于定量评估的数据集是什么？代码有没有开源？
 - a. 数据集：
 - i. 2D：ISIC2016、Kvasir-SEG、IDRiD
 - ii. 3D：ACDC、Synapse
 - b. 代码：<https://github.com/NKUhealong/H2Former>
9. 论文中的实验及结果有没有很好地支持需要验证的科学假设？
 - a. 有很好地支持
 - i. 在所有数据集上均显著优于CNN、Transformer及其他混合方法。
 - ii. 消融实验明确表明CNN、MSCA、Transformer模块缺一不可，证明层次化融合策略的有效性。
10. 这篇论文到底有什么贡献？
 - a. 首提三重融合架构：CNN局部特征 + Transformer全局依赖 + 多尺度通道注意力
 - b. 创新MSCA模块：通道维度多尺度建模与动态校准
11. 下一步有什么工作可以继续深入？
 - a. 没有什么特别有价值的想法

Ref:


1. 文章中多尺度通道注意力(MSCA)工作机制?
 - a. 在多尺度特征融合过程中 **引入多个不同分辨率的通道上下文表示**，然后 **融合这些尺度的通道注意力信息**
 - i. 多尺度上下文提取，对输入特征做**多个不同尺度的全局平均池化(GAP)**
 - ii. 共享或独立的MLP进行通道注意力生成
 - iii. 将这些不同尺度的通道注意力权重
2. 为什么要GAP? 能达到什么效果?
 - a. 每个通道在空间维度上做平均（对 $H \times W$ 区域求平均），最终得到每个通道的一个**全局表示**（即每个通道一个值）
 - i. 在注意力中压缩空间维度，特征图压缩为 $C \times 1$ ，只保留通道信息
 - ii. 建模通道重要性，计算开销低？
3. MLP怎么生成通道注意力？
 - a. 学习不同通道的重要性权重，并对每个通道进行加权调整，以提升有用特征、抑制冗余通道
4. 还有没有其他融合方式？优劣？
 - a. 加权求和稳定高效，其他还有比如拼接 + MLP or 门控融合
5. 文章对于模型效率的优化有哪些？这个模型还能怎么进一步优化效率？
 - a. 文章的核心是采用**GAP + MLP (MSCA)代替Transformer自注意力提升效率**
 - i. 层次化设计，通过编码器多阶段下采样逐步降低分辨率
 - ii. MSCA 使用多尺度的全局平均池化（GAP）+ MLP，对每个通道生成注意力权重
 - iii. 多尺度卷积核（如 3×3 , 5×5 ）融合局部上下文，不依赖重型的 Transformer 注意力
6. GAP + MLP (MSCA)是怎么能替代Transformer效果的？有局限性？牺牲了什么？
 - a. 医学图像中区域同质性强，MSCA 聚焦通道维度信息交互，GAP+MLP 可以压缩/强调有效语义通道
 - b. 牺牲了建模空间位置依赖，长距离依赖，不能处理跨区域多模态，那简单来说，文章牺牲了精度，其实效果只能在有限的数据集应用，缺乏普遍性

HRMedSeg: Unlocking High-resolution Medical Image segmentation via Memory-efficient Attention Modeling

1. 文章试图解决什么核心问题？
 - a. 如何在高分辨率医学图像上进行高效、精确的图像分割，同时控制模型计算量与内存开销。
2. 这是否是一个新问题？为什么会存在这个问题？
 - a. 医学图像需高分辨率以捕捉微结构，但传统UNet和ViT计算复杂度大
 - b. 现有解决方案（如线性注意力、移除跳跃连接）往往牺牲模型表达能力或多尺度学习能力
3. 这篇文章要验证一个什么样的科学假设？
 - a. 将 CNN 和 Transformer 进行轻量级并行融合，可以在不牺牲精度的前提下，实现对高分辨率医学图像的高效分割。
 - i. 线性复杂度的注意力机制
 - ii. 跨尺度解码设计
4. 有哪些相关研究？如何归类？谁是这一课题在领域内值得关注的研究员？
 - a. CNN-based分割
 - i. U-Net (Ronneberger et al., 2015)
 - ii. U-Net++ (Zhou et al.)
 - iii. Attention U-Net (Oktay et al.)
 - iv. nnU-Net (Isensee et al.)
 - b. Transformer-based分割
 - i. TransUNet (Chen et al. 2021)
 - ii. Swin-Unet (Cao et al. 2022)
 - iii. UCTransNet (Wang et al.)
 - iv. MedFormer (2022)
 - c. 高分辨率建模相关：
 - i. HRNet (Sun et al.)
 - ii. HRFormer (Yuan et al. 2022)
5. 论文中提到的解决方案之关键是什么？方法中的每个子模块对应解决了这个问题当中的哪一个环节或者什么关键点？
 - a. 方法关键：并行CNN-Transformer高分辨率分割网络



- b. 双门控结构的并行Encoder设计：
 - i. 通道交互层 (MBConv)：提取低层特征
 - ii. 令牌交互层 (DGLA)：线性复杂度全局建模
 - iii. 当层并行特征融合后再传递下一层
- c. ECM-Decoder：避免免金字塔解码，减少跳跃连接的内存开销
- 6. 和其他相关工作相比，有哪些优化？或者有哪些创新点？
 - a. 轻量并行架构（不是串联CNN+Transformer，而是并行）



- b. 双门控线性注意力 (DGLA)
 - i. 在令牌交互层引入内部门控(IG)和外部门控(EG)
- c. 跨尺度解码器 (ECM-Decoder)
 - i. 用多尺度池化替代传统跳跃连接
- 7. 论文中的实验是如何设计的？
 - a. 训练配置：
 - i. 分辨率：1024×1024
 - ii. Batch Size：16
 - iii. 优化器：Adam (LR=10⁻⁴)
 - iv. 损失函数：Dice + Focal Loss
 - b. 指标：Dice/Hausdorff Distance (HD95)/mIoU
 - c. 消融实验：
 - i. 测试是否采用并行结构
 - ii. 是否有FAM、Decoder结构变化
- 8. 用于定量评估的数据集是什么？代码有没有开源？
 - a. 数据集：
 - i. Synapse multi-organ CT
 - ii. ISIC2018
 - iii. Brain tumor dataset (BraTS)
 - iv. Kvasir, Polyp datasets
 - b. 开源：<https://github.com/xq141839/HRMedSeg>
- 9. 论文中的实验及结果有没有很好地支持需要验证的科学假设？
 - a. 支持充分：
 - i. Ablation实验：并行结构、FAM模块的加入均带来明显性能提升
 - ii. 在所有数据集上性能对比TransUNet、Swin-Unet更优
 - iii. 参数量和FLOPs显著下降，验证轻量化目标实现
- 10. 这篇论文到底有什么贡献？

- a. 首个针对高分辨率医学图像的内存高效分割框架HRMedSeg
- 11. 下一步有什么工作可以继续深入?
 - a. 没想到什么真的能做的

Ref:


1. 该文章强调高分辨率医疗图像，他和其他一般的医疗图像有啥不同？有什么突出挑战？
 - a. 高分辨率与细节捕捉，数据量巨大，从而导致：
 - i. 内存消耗大
 - ii. 计算复杂
 - iii. 多尺度特征融合困难
2. 文章为什么要并行结构？CNN+Transformer串行不行吗？
 - a. CNN提取的是局部特征，Transformer提取的是全局信息，如果串行：
 - i. 先CNN再Transformer，本质是单通路传播，一方信息会被另一方模糊覆盖
 - ii. 串行没有并行这样，可以在中间层有交互，局部和全局特征不能保持互补
3. 文章的DGLA是怎么实现O(N)复杂度的？
 - a. **线性核函数替换Softmax**：论文中引入了类似于 Performer 的思想，即将注意力公式重写为（作者采用的核函数类似于 $\phi(x)=\text{elu}(x)+1$ 核函数）

$$\text{Attention}(Q, K, V) = \frac{\phi(Q)(\phi(K)^T V)}{\phi(Q)(\phi(K)^T \mathbf{1})}$$

- b. Swin局部窗口划分
 - c. 注意力共享：引入了 group-shared Q/K/V 或 group pooling 的策略，进一步降低矩阵乘法数量
4. 为什么可以用线性核函数替换？是近似？还有没有更优的核函数？
 - a. 用线性核函数代替 Softmax 是一种**可控损失下的近似**，换取线性复杂度（O(N)）
 - b. 常用核函数如 ELU+1、exp、RFF、learnable $\phi(x)$ 等都已尝试，ELU+1是比较强和稳定的baseline

SegFormer3D: an Efficient Transformer for 3D Medical Image Segmentation

1. 文章试图解决什么核心问题?
 - a. 如何在 3D 医学图像分割中, 保持 Transformer 强大的全局建模能力,
 - i. 显著降低模型参数量和计算复杂度
 - ii. 小数据集容易过拟合
2. 这是否是一个新问题? 为什么会存在这个问题?
 - a. 不是全新问题, 但在 **3D 医学影像** 领域是 **尤为突出** 的问题
 - i. 医学SOTA模型堆叠Transformer层, 忽视医学数据重复结构特性
 - ii. 在3D体素下, 展开为1D序列时, 导致计算量剧增
3. 这篇文章要验证一个什么样的科学假设?
 - a. 通过**序列压缩+层次化特征融合**, 可实现轻量化3D分割模型
 - i. 高效自注意力, 复杂度可从 $O(n^2) \rightarrow O(n^2/r)$, r 为压缩率
 - ii. MLP解码器代替CNN解码器, 可避免参数激增
4. 有哪些相关研究? 如何归类? 谁是这一课题在领域内值得关注的研究员?
 - a. 基于 CNN 的 U-Net 变种
 - i. U-Net (Ronneberger et al. 2015)
 - ii. V-Net (Milletari et al. 2016)
 - iii. nnUNet (Isensee et al. 2018)
 - iv. PGD-UNet (Li et al. 2020)
 - b. Transformer + CNN 混合架构
 - i. TransUNet (Chen et al. 2021)
 - ii. UNETR (Hatamizadeh et al. 2022)
 - iii. nnFormer (Zhou et al. 2021)
 - iv. TransBTS (Wang et al. 2021)
 - v. SwinUNETR (Hatamizadeh et al. 2021)
 - c. 全 Transformer 架构
 - i. SegFormer (Xie et al. 2021)
 - ii. Pyramid ViT (Wang et al. 2021)
 - d. Transformer 高效化
 - i. EfficientViT (Liu et al. 2023)
 - ii. Linformer (Wang et al. 2020)
5. 论文中提到的解决方案之关键是什么?
 - a. 方案关键: hierarchical Transformer 替代大 ViT, 结合 Efficient Attention 和 All-MLP



- b. 重叠块嵌入 Overlapping Patch Embedding
 - i. **卷积+卷积步长stride < kernel size**, 保留体素邻域信息, 避免边界信息丢失
- c. Hierarchical Transformer Encoder
 - i. 多尺度提取 coarse-to-fine 特征, 减少 token 数
- d. Efficient Self-Attention
 - i. 将 K、V reshape, 压缩到较低维度, 复杂度从 $O(N^2) \rightarrow O(N^2/r)$
- e. Positional-Free Encoding
 - i. 避免固定 positional encoding, 适应医学影像多尺度问题
- f. All-MLP Decoder
 - i. 简单 Linear Layers 解码来代替conv, 减少参数和FLOPs
6. 和其他相关工作相比, 有哪些优化? 或者有哪些创新点?
 - a. **Efficient Attention**
 - i. QK矩阵稀疏化, 减少内存和计算
 - b. **All-MLP Decoder**
 - i. 用线性层代替卷积, 更简单、更少参数
 - c. **Positional-Free Encoding**
 - i. 无需手工 positional embedding, 适配不同分辨率
7. 论文中的实验是如何设计的?
 - a. 对比模型: 8类SOTA (nnFormer/UNETR/TransUNet等)
 - b. 评估指标: Dice系数 (器官级/平均)
 - c. 训练:
 - i. 单卡RTX 3090, AdamW优化器 ($lr=3e-5$)
 - ii. 损失函数: Dice-CE混合损失
 - iii. 无预训练 (强调小数据泛化性) (Section 4)
 - d. 消融实验:

- i. 不同的efficient Attention reduction rate
 - ii. 不同的decoder设计: MLP vs conv
 - iii. Hierarchical Encoder vs. Single-Level Encoder
 - iv. Positional Embedding vs. No Positional Embedding
- 8. 用于定量评估的数据集是什么? 代码有没有开源?
 - a. 数据集: BraTS/Synapse/ACDC
 - b. 代码开源: <https://github.com/OSUPCVLab/SegFormer3D.git>
- 9. 论文中的实验及结果有没有很好地支持需要验证的科学假设?
 - a. 完全支持:
 - i. 在 BraTS 上参数少 34×
 - ii. Synapse 上, SegFormer3D 几乎接近 nnFormer, 且比多数模型好
 - iii. ACDC: SegFormer3D 与 nnFormer 相差仅约 1%
- 10. 这篇论文到底有什么贡献?
 - a. 首次将 SegFormer 思想扩展到 3D 医学影像
 - b. 提出 Efficient Self-Attention, 用 $O(N^2/r)$ 近似 $O(N^2)$
- 11. 下一步有什么工作可以继续深入?
 - a. **可变stride的conv算子**, 支持adaptive的:
 - i. Hierarchical Transformer Encoder, 详见Ref 1-4
 - ii. Overlapping Patch Embedding, 详见Ref 5-7
 - b. a的但是挑战巨大, 本身写一个定制化可变stride的算子就足够一篇文章工作量, 大致思路, 但可工程上通过**伪可变stride**实现:
 - i. **分区域做block-wise convolution**: 把feature map划成block, 每个block用同一个stride, 同stride的block一次conv, 再把block拼回去, 比较现实的做法是:
 - 1. 输入: **feature map + stride map**
 - 2. PyTorch C++ API + cuDNN + Mask
 - a. 遍历stride_map把pixel按stride分组, 生成多个masks
 - b. 调用cuDNN的conv跑对保留stride区域跑对应的stride
 - c. 合并所有结果封装成C++ extension, 在pytorch层调用
 - 3. 卷积不是会对附近像素做乘积累加, 怎么可能做到分stride一起conv?
 - a. 工程上只能做到**block level的有限可变stride卷积**, 分析详见 Ref 12

Ref:

- 1. 什么叫Hierarchical Transformer Encoder, 为什么能减少token数?
 - a. N层原生ViT: 图像切成固定大小的patch, 每个patch一个token
 - b. Hierarchical Encoder: 类似Unet做了下采样, 每一层随着resolution下降token数减少

$$N = \frac{H}{P} \times \frac{W}{P} \times \frac{D}{P}$$

- 2. Resolution越低, 需要保留信息的token数越少可以理解, 但是为什么resolution下降不会影响精度呢?

- a. 医学图像信息分布不是均匀的，且高度冗余，多尺度存在，**虽然 spatial 尺寸变小，但每个 token 的 receptive field 变大，能覆盖更大的区域信息**
3. 如何理解虽然 spatial 尺寸变小，但每个 token 的 receptive field 变大？
 - a. **在Transformer，每层都在融合交互信息，token本质上类似放大镜，可视野就是随着层数加深会变大**
 - b. 假设在深度一样的vanilla ViT vs Hierarchical Transformer，同一层的token，原生的 ViT 的 **token 数和物理 patch 恒定，只是信息 receptive field 在增加，物理可视野并未增大**；而 Hierarchical Transformer 同时让 token 数减少、token 覆盖区域变大，**则对应的物理可视野更大，信息可视野比原生的更大**
4. 这里尺度变小的策略是怎么样设定的？下采样固定stride变小吗？可变stride会更好吗？
 - a. 固定stride不是最优，因为**不同区域信息密度差异很大，在信息密度高的区域，stride可以小，稀疏区域，stride可以大**
 - b. 工程上固定stride计算简单，容易写成 CUDA kernel，大概率需要**重新写CUDA算子，现有算子都只支持固定stride**
5. 什么是Overlapping Patch Embedding，他能解决什么问题？
 - a. Transformer embedding需要把图片切成patch输入，patch 不重叠，彼此独立，**因此不保留局部连续信息，容易出现 block effect (块效应)**
 - b. 而Overlapping patch embedding核心是1. **用卷积代替slicing** 2. **stride<kernel size**，则相邻patch可以保留共享的像素连续性，减少块效应
6. 原文怎么选stride的？可变stride会更好吗？
 - a. 原文stride=4，根据工程经验，stride=patch size/2, 可以获得效率和连续性的平衡
 - b. **可变stride绝对可能更优，不同区域的信息密度不同，病灶区域需要更多overlap，stride应该更小；无关区域stride可以更大**
7. 这个思路和前面可变stride的hierachical Transformer是类似的，但是这有两个挑战问题，怎么事先就知道哪些区域(token)是信息密度区域，哪些不是？以什么标准判定？还有把slicing换成conv，还可变stride，本身岂不是又增加了计算量？和原本降低计算量的目标背道而驰吧？
 - a. 可以围绕variance/gradient/entropy/attention scores/multi-scale uncertainty设定判定标准，简单的比如：
 - i. 利用Self-attention map注意力分数本身，attention weight高则代表区域信息丰富，可以对 Q-K 矩阵做 pooling：

$$\text{importance}(i) = \frac{1}{N} \sum_{j=1}^N \text{Attention}(i, j)$$
 - b. 可变 stride overlapping patch embedding 不一定必然更贵，核心在于如何选择应用：大区域 stride 大节省 compute，甚至不做overlapping；小区域 stride 小保留 detail。难点是**如何高效识别 high-information 区域，以及如何实现 dynamic stride 的 kernel**
8. 原文的efficient attention是如何做矩阵稀疏化的？
 - a. 把原本 N×N 的 big matrix，变成 N×r 的小矩阵，再做乘法，避免存储全注意力矩阵， $A=Q \cdot K^T \rightarrow A \approx Q \cdot (\text{Reduced-}K^T)$
 - b. 作者用token pooling或者类似mean pooling，将K减少到r个 token -> $A_{\text{efficient}} = Q \cdot \text{pooled } K^T$ ，再做聚合 $\text{Output} = \text{Softmax}(dQ \cdot K_{\text{pooled}}^T) \times V_{\text{pooled}}$
 - c. 只计算 token 与 r 个“代表性 token”之间的关系，而不是 token 与所有 token 之间，本质上是一种**低秩近似的方法 - 医学数据feature map里信息冗余，rank就低**

9. 怎么选取 r 呢? 如何选最优?
 - a. Linformer (Wang et al. 2020)里的经验法 $r \approx \log(N)$
 - b. 文章中通过实验, $r=N/4$ or $N/8$ 几乎不掉精度
10. 文章为什么要Positional-Free Encoding? 为啥不需要position信息也没影响精度?
 - a. 原生ViT里, 做完embedding后, 需要每个token加个position embedding 向量, $E_{input}=E_{patch}+E_{position}$, 保持空间连续性信息
 - b. **文章里做了overlapping conv, 卷积和多尺度本身就有位置信息, 而医学影像对绝对位置不敏感**
11. 为什么文章可以用All-MLP decoder?
 - a. 因为前面设计encoder已经足够提取global+local feature, 用MLP融合feature经过实验验证几乎没影响, 但是节省内存和计算
12. 卷积不是会对附近像素做乘积累加, 怎么能用 mask 跑一次 conv? mask 区域都为 0, 难道对卷积没影响吗?
 - a. mask 区域确实会对卷积影响, 卷积会跨 mask 边界, 导致 boundary leakage, 解决方案: **每个 stride 区域, 单独裁剪出一个 feature block**, 再 conv
 - i. 若 region 连续 $\rightarrow$ crop 最好
 - ii. 若 region 零碎 $\rightarrow$ mask 也行, 但会引入零值
 - b. 所以最后的方法是, 无法实现像素级别的stride conv, 只能在feature map上先分好block, 然后按照block做不同stride的conv, 最后再把结果拼回去, 这样能把0值影响到最低, 只在边缘, 其实就是**有限的可变stride卷积**

EffiDec3D: An Optimized Decoder for High-Performance and Efficient 3D Medical Image Segmentation

1. 文章试图解决什么核心问题？
 - a. 现有的 3D 医学图像分割模型虽然准确率高，但：
 - i. 参数量极大，计算开销 巨大
 - ii. 精度-效率失衡：现有高效模型（如UNETR++）以牺牲精度换取效率
 - iii. 难以在实时场景或资源有限环境（如边缘设备、医院低配 GPU）中部署
 - b. 尤其是高分辨率 decoder 阶段、通道数过多，是计算瓶颈
2. 这是否是一个新问题？为什么会存在这个问题？
 - a. 不是全新问题，但本文是对 3D segmentation decoder 优化方案
 - b. 存在这个问题的原因：
 - i. decoder 需要恢复空间分辨率，每次渐进式上采样都伴随，高维卷积，包含高分辨率的冗余
 - ii. 同时通道机械递增，包含大量冗余通道
3. 这篇文章要验证什么样的科学假设？
 - a. 高分辨率层与大通道数 decoder，并不是维持 segmentation 精度的必要条件，即
 - i. **最小化通道数**，可减少冗余参数
 - ii. **选择性移除高分辨层**，可减少FLOPS不一定显著牺牲分割精度
4. 有哪些相关研究？如何归类？谁是领域内值得关注的研究员？
 - a. CNN-based 3D segmentation：
 - i. 3D U-Net (Çiçek et al.)
 - ii. nnUNet (Isensee et al.)
 - iii. ResUNet
 - iv. MedNeXt
 - b. Transformer-based 3D segmentation
 - i. UNETR
 - ii. SwinUNETR
 - iii. SwinUNETRv2
 - iv. TransBTS
 - v. nnFormer
5. 论文中提到的解决方案之关键是什么？方法中的每个子模块对应解决了什么问题
 - a. **Channel Reduction**：首次将**所有阶段通道数压缩至编码器最小值**
 - b. **Resolution Restriction**：不再将decoder输出恢复到原始分辨率，而是一半，再通过tri-linear upsampling，避免上采样卷积开销
6. 和其他相关工作相比，有哪些优化？或者有哪些创新点？
 - a. 提出全局减少通道数而非局部修改
 - b. 半分辨率输出
7. 论文中的实验是如何设计的？
 - a. 在多种骨干网络上测试：
 - i. 3D UX-Net
 - ii. SwinUNETR
 - iii. SwinUNETRv2

- b. 消融实验
 - i. 不同resolution
 - ii. 不同decoder通道数
 - 8. 用于定量评估的数据集是什么？代码有没有开源？
 - a. 12 个 benchmark
 - i. FeTA (胎脑)
 - ii. BTCV (腹部13器官)
 - iii. MSD (10种分割任务)
 - b. 代码开源: <https://github.com/SLDGroup/EffDec3D>
 - 9. 论文中的实验及结果有没有很好地支持需要验证的科学假设？
 - a. 完全支持
 - b. 主实验 (Table 1-3) :
 - i. FeTA数据集: FLOPs减少92%
 - ii. BTCV数据集: 参数量减少94%时精度持平
 - c. 消融实验:
 - i. 半分辨率输出 vs 全分辨率: 精度差<0.5%, FLOPs↓89% (Table 4) 。
 - ii. 通道数48为最优: 高于56时精度饱和, FLOPs激增 (Table 5)
 - 10. 这篇论文到底有什么贡献？
 - a. 提出EffDec3D 的贡献:
 - i. 系统性分析 3D seg decoder的FLOPs/参数瓶颈
 - ii. 提出全局减少通道
 - iii. 半分辨率输出
 - iv. 即插即用解码器且精度并未牺牲太多
 - 11. 下一步有什么工作可以继续深入？
 - a. Ref 2分析, 可以采取其他更平衡的策略选最优通道数, 而不是一定是全局最小
 - b. Ref 3分析, 可以采取adaptive的输出分辨率, 但是个人感觉做的意义不大, 基本就是1和1/2两种选择
 - c. 可以结合硬件部署, 做quantization和pruning, 但是做的就偏工程了, 对比前2个创新点, 这个反而更实在些
 - d. **结合上面3点, 做可adaptive的通道数选择+分辨率选择+可部署的验证**


Ref:

- 1. 作者是怎么想到对编码器优化的？是因为编码器的计算量和参数量在Unet结构中占比比较大？
 - a. 其他论文都习惯先动encoder, 因为encoder负责特征提取, 但作者在文中通过**profiling统计了decoder部分的FLOPs并不比encoder少**, 尤其在高分辨率和大数量通道
 - b. decoder的上采样结构决定其feature map不断变大, skip connection通道堆叠
- 2. decoder的通道数最小化是怎么找出最小值的？有没有其他方法找出最小值？
 - a. **decoder选取的最小值即是encoder各skip connections中的通道最小值**, 这里用的是最简单最安全的策略, 每一层skip connection只需要min(C)个通道来表示特征
 - b. 其他策略:
 - i. learnable channel gating: 让网络通过负反馈学习选出最重要的通道
 - ii. 不需要全局最小, 可以通过逐渐选个局部最小, 或者阶梯式选最小

3. 文章为什么可以选择半分辨率输出，而没有太大影响精度？为什么是1/2？不能其他百分比吗？
- a. 医疗分割中，多数器官边缘比较平滑，**本身就有一点物理模糊**，因此牺牲分辨率不一定会造成精度下降
 - b. 文章做了消融实验，证明1/2时候loss最小，但是可以考虑adaptive的分辨率：
 - i. 大器官->1/2
 - ii. 小器官->1

EMF-former: An Efficient and Memory-Friendly Transformer for Medical Image Segmentation

1. 文章试图解决什么核心问题?
 - a. 在保持医学图像分割精度的同时, 大幅降低 Transformer 模型的计算开销和内存占用, 实现轻量化和高效性。
2. 这是否是一个新问题? 为什么会存在这个问题?
 - a. 不是全新问题, 但该论文在轻量化 Transformer 方向上提出了新的方法
 - b. 存在问题原因:
 - i. Transformer 的自注意力是全局操作, 复杂度为 $O(N^2 \cdot d)$
 - ii. 多头注意力**并行存储中间结果** (如Q/K/V矩阵) **导致内存峰值过高**
3. 这篇文章要验证一个什么样的科学假设?
 - a. 轻量化卷积模块 (DSPConv) 替代标准卷积, 减少参数量。
 - b. 向量聚合注意力 (VAA) 将矩阵乘法转化为向量广播+逐元素乘, 降低计算复杂度
 - c. 串行多头注意力 (S-MHA) 按序计算注意力头, 减少冗余和内存占用。
4. 有哪些相关研究? 如何归类? 谁是这一课题在领域内值得关注的研究员?
 - a. **轻量化卷积**
 - i. ShuffleNet, MobileNet -> 未针对医学图像优化特征交互
 - b. **轻量化Transformer**
 - i. EfficientFormer (Li et al. 2022)
 - ii. Rest (Zhang et al. 2021)
 - iii. SwiftFormer (Shaker et al. 2023)
 - iv. EdgeViT (Pan et al. 2022)
 - c. **注意力机制优化**
 - i. CCNet (Huang et al. 2023) → Criss-Cross Attention
 - ii. ShuffleNet (Ma et al. 2018) → Channel Shuffle
 - iii. SwiftFormer → Additive Attention
 - iv. Batformer → Boundary-aware Attention
5. 论文中提到的解决方案之关键是什么? 方法中的每个子模块对应解决了这个问题当中的哪一个环节或者什么关键点?
 - a. 方案关键: EMF-Former



b. DSPConv (Depthwise Separable Shuffled Convolution)

- DWConv -> 降低卷积参数
- Channel Shuffle -> 不同通道信息交互
- PWConv -> 特征融合

c. 向量聚合注意力Vector Aggregation Attention (VAA)

- 不做 $Q \times K$ 大矩阵乘法->逐元素操作, 复杂度降低到 $O(N)$

$$VAA_{Attn}(Q, K) = L \left(\frac{Q_{\alpha} K_{\alpha}}{\sqrt{C}} \right) + K. \quad (5)$$

d. 串行多头注意力(S-MHA)

- 不并行计算所有head -> 分组进行串行计算, 并跳过偶数多头, 减少50%内存

6. 和其他相关工作相比, 有哪些优化? 或者有哪些创新点?

a. 文章3个创新模块代表创新点:

- DSPConv -> channel shuffle减少信息丢失, 优于传统的depthwise conv
- Vector Aggregation Attention (VAA) -> 元素成绩代替大矩阵乘法
- Serial Multi-Head Attention (S-MHA) -> 分组串行计算

7. 论文中的实验是如何设计的?

- 评估指标: mIoU/Pixel Accuracy (Acc)/参数量/内存使用
- 消融实验**: 分别单独测试3个创新模块DSPConv, VAA, S-MHA

8. 用于定量评估的数据集是什么? 代码有没有开源?

- 数据集: ACDC (心脏 MRI), Hippocampus (脑 MRI)
- 代码未开源

9. 论文中的实验及结果有没有很好地支持需要验证的科学假设?

- 完全支持:
 - 相比TransUnet、SegFormer, 在ACDC+Hippocampus两个数据集中参数大量下降

- b. 消融实验表明:
 - i. DSPConv 和VAA能单独提升mIoU
 - ii. S-MHA单独减少参数
- 10. 这篇论文到底有什么贡献?
 - a. 提出EMF-former, 其中DSPConv降低卷积参数, VAA降低注意力计算复杂度, S-MHA减少内存消耗
- 11. 下一步有什么工作可以继续深入?
 - a. 在DSPConv中更智能的 Channel Selection -> 个人觉得没有很大价值, 分析见深度挖掘2-3
 - b. 在VAA中, 可以进一步探索更智能的token aggregation, 分析见Ref 4-5
 - c. 在S-MHA中, 可以进一步探索其他分组方式提高精度同时保留效率, 分析见Ref 6-7

Ref:

1. 作者是怎么想到3个模块的创新点? 基于什么样的问题分析找到创新点的?
 - a. 作者思考逻辑链来自于3个方向
 - i. Transformer参数量大, 并行计算内存高 -> 能否做卷积又少参数, 又不信息丢失, 不同通道能信息流通 -> 参考ShuffleNet + Selective DWConv -> 只在1/4channel做DWConv减少参数, 同时channel shuffle保证信息流通
 - ii. Transformer自注意力计算量大 -> 参考SwiftFormer, Lin et al. -> 能否用向量替代矩阵乘法 -> VAA
 - iii. 多头计算都是并行 -> 改串行, 同时并非做所有的head
2. DSPConv核心是什么呢? 为什么只用做1/4通道的卷积而不影响性能? 是否意味着Transformer卷积中有大量无效的计算? 怎么筛选出这1/4的有效通道呢?
 - a. 首先理解Spatial Conv vs. Pointwise Conv
 - i. Spatial Conv: 正常的NxN滑动卷积, 用于**捕捉空间局部特征**, 如边缘, 角点, 纹理等
 - ii. Pointwise Conv: 1x1卷积, 不看周围像素, 只对单个像素操作, **在通道维度做加权和**
 - b. 因为NxN卷积计算量大, 因此选择不需要对所有的通道做NxN卷积, 在实际feature map里, **只有少数通道包含关键空间信息**, 即很多通道是冗余的
 - c. 文章并没有做**硬性通道筛选**, 只是简单的用前1/4的通道, 在实验中, 其实是通过end to end学习, 让重要的feature map**自然被encode到前1/4通道里**
3. 接上题, 为什么这个自然筛选会发生? 是否意味着就不需要做特意筛选了?
 - a. 训练时有loss function监督, 某些channel的loss贡献大, 则梯度大; 反之不重要的loss, 梯度就会趋近于0, 因此feature会自动占据显著的channel, DSPConv的操作是固定的, 对前1/4通道做DWConv, 对后3/4 channel做1x1卷积, 因此会主动前移
 - b. 能否做特殊筛选做得更好? 应该可以通过channel加权, 动态选择channel等加一些筛选机制, 但个人觉得价值不是很大
4. 向量聚合注意力Vector Aggregation Attention (VAA)为什么能通过单个元素的操作代替或者近似QxK大矩阵乘法呢? 中间损失的是什麼?
 - a. 首先理解传统自注意力, A是NxN矩阵, **A_{ij}其实是计算第i个token和第j个token的pairwise相似度**

$$A = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right)$$


- b. VAA解决的是：真的需要每个token和N个token比较吗？**每个token只和1个global mean token比较**，这里保留了global context的信息，牺牲了token to token的局部精细建模，适合医疗中高度同质化的背景，平滑区域，不适合小目标，或者高度局部差异化的任务
- 5. 接上一个问题，为什么是global mean token？用中值median行不行？
 - a. Median需要 $O(n \log n)$ 排序，其实并不一定更省计算
 - b. 可以考虑：
 - i. Sum Pooling：强调背景信息
 - ii. **Max Pooling：强调局部极值，可以捕捉一些病灶信息**
 - iii. Weighted Mean：自动学习哪些token更重要
 - iv. Feature分层pooling：window mean pool, global mean pooling再concat, 保留local和global信息
- 6. S-MHA分组串行，是不是就是用时间换空间？inference的latency不会增大吗？
 - a. 是的，这是一个trade off
- 7. 怎么分组？有没有其他分组方式？其他分组方式理论上不能进一步减少内存，但是能提升性能吗？
 - a. 原文舍弃掉了偶数feature，**因为作者认为偶数head常常和奇数head重复**
 - b. 可以random skip, learnable gating等等，作者假设奇数一定是冗余的，但其实并不一定，**通过learnable的gating取判断丢掉的feature是否重要**，是有可能提升性能的

DA-TransUNet: integrating spatial and channel dual attention with transformer U-net for medical image segmentation

1. 文章试图解决什么核心问题?
 - a. 现有的Transformer-based 医学图像分割网络虽然具备强大的全局特征提取能力, 但
 - i. 缺乏对**空间/位置细节**(如器官边界)和**通道特征**(如组织对比度)的精准捕捉;
 - ii. 同时, 模型参数量和计算开销往往很大
2. 这是否是一个新问题? 为什么会存在这个问题?
 - a. 不是全新问题, 但优化方向有创新
 - i. Transformer在医学图像已经广泛应用进行全局建模
 - ii. 双注意力机制 (Dual Attention, DA) 在自然图像分割已有应用, 但尚未被系统性优化并集成到医学图像分割中
 - iii. Skip connection 在医学图像分割中广泛使用, 但直接传递特征可能带入冗余信息, 没有针对性地筛选有用信息
 - b. 存在问题原因
 - i. 医学图像比自然图像有**更高的分辨率、更多细节**, 对**局部细节** (病灶边缘) 和**全局语义** (器官结构) 需要同时兼顾, 而**Transformer 本身并不针对这种细粒度特征设计**
 - ii. 双注意力机制 (如DANet) 在自然图像有效, 但未针对医学图像的高精度需求优化通道压缩率与位置特征融合
3. 这篇文章要验证一个什么样的科学假设?
 - a. 将优化后的**双注意力模块 (DA-Block) 与Transformer结合**, 嵌入U-Net架构的**编码器和跳跃连接**中, 能显著提升医学图像分割精度。具体包括:
 - i. DA-Block可提取医学图像特有的**空间位置**和**通道特征**。
 - ii. 跳连接中的**DA-Block能过滤冗余信息**, 解决语义鸿沟问题。
4. 有哪些相关研究? 如何归类? 谁是这一课题在领域内值得关注的研究员?
 - a. 基于 CNN 的 U-Net 变种
 - i. U-Net (Ronneberger et al., 2015) – 最经典结构
 - ii. U-Net++ (Zhou et al., 2018) – 优化 skip connections
 - iii. ResUnet (Diakogiannis et al., 2020) – 残差机制融入 U-Net
 - iv. Attention U-Net (Oktay et al., 2018) – 添加软注意力
 - b. Transformer 与 U-Net 结合
 - i. TransUNet (Chen et al., 2021)
 - ii. Swin-Unet (Cao et al., 2022)
 - iii. TransNorm (Azad et al., 2022b)
 - iv. UCTransNet (Wang et al., 2022a)
 - v. MIM (Wang et al., 2022b)
 - c. Dual Attention (DA) 在分割任务中的应用
 - i. DANet (Fu et al., 2019) – 自然场景分割。
 - ii. DAResUnet (Shi et al., 2020) – 在医学图像中引入 DA。
 - iii. DA-DSUnet (Tang et al., 2021) – 应用于头颈部肿瘤。
 - iv. Multilevel Dual Attention U-net for Polyp Segmentation (Cai et al., 2022)
 - d. 关键研究者:

- i. Transformer医学应用: Chen (TransUNet) 、Cao (Swin-Unet)
 - ii. 双注意力机制: Fu (DANet) 、Shi (DAResUnet)
5. 论文中提到的解决方案之关键是什么? 方法中的每个子模块对应解决了这个问题当中的哪一个环节或者什么关键点?

DA-TransUNet



- a. 方法关键: DA-Block (PAM + CAM)
 - i. 精细提取图像的空间位置特征 (PAM)
 - ii. 精细提取图像的通道依赖关系 (CAM)
 - iii. 弥补 Transformer 缺少空间和通道特征的不足
 - b. 子模块Encoder+DA Block
 - i. CNN提取局部特征
 - ii. DA-Block增强空间和通道细节
 - iii. Transformer整合全局信息
 - c. Skip connection + DA Block
 - i. 过滤冗余信息, 解决编码器-解码器语义鸿沟
 - d. Decoder
 - i. 使用上采样恢复分辨率, 将 refined skip features 与编码器特征融合
6. 和其他相关工作相比, 有哪些优化? 或者有哪些创新点?
 - a. 首次将DA-Block与Transformer结合, 针对性优化医学图像特征提取
 - b. 跳跃连接逐层嵌入DA-Block, 对skip feature做attention filtering, 保留最关键信息
 - c. 更少的参数增长, 性能提升大
7. 论文中的实验是如何设计的?
 - a. 实验设置:
 - i. 对比模型: 11种SOTA模型 (U-Net系列、Transformer系列、注意力模型)
 - ii. 评估指标: Dice系数 (DSC) 、IoU、Hausdorff距离 (HD)
 - iii. 消融实验: 验证DA-Block位置 (编码器/跳连接)、通道压缩率、层数影响
 - b. 训练细节:
 - i. 优化器: Adam (lr=1e-3) 或SGD (Synapse) 。
 - ii. 损失函数: Dice Loss + Cross-Entropy/Binary Cross-Entropy。

8. 用于定量评估的数据集是什么？代码有没有开源？
 - a. 数据集：6个医学图像数据集（见表2）：
 - i. Synapse (3D腹部CT)、CVC-ClinicDB (结肠镜)、Chest X-ray、Kvasir-SEG、Kvasir-Instrument、ISIC2018 (皮肤镜)
 - b. 开源：<https://github.com/SUN-1024/DA-TransUnet>
9. 论文中的实验及结果有没有很好地支持需要验证的科学假设？
 - a. 完全支持，DA-TransUNet 在 6 个数据集上，均超越了 TransUNet 和其他 SOTA 模型。
 - b. 消融实验证明：
 - i. DA-Block 加在 encoder → 性能提升。
 - ii. DA-Block 加在 skip connections → 性能进一步提升。
 - iii. 将 DA-Block 中间通道缩到 1/16，效果最优。
10. 这篇论文到底有什么贡献？
 - a. 提出DA-TransUNet，首次融合双注意力与Transformer优化医学图像分割。
 - b. 设计医学图像专用的DA-Block（通道压缩率1/16），在encoder+skip connections 同时使用，提升分割效果
11. 下一步有什么工作可以继续深入？
 - a. 将 DA-TransUNet 用于多模态(e.g.MRI/CT)，医学多模态数据存在空间对齐需求(如不同模态的解剖结构对应)和通道关系建模，而DA-Block恰恰能解决这2个问题，但是单纯应用DA-TransUNet到多模态只是应用，不能叫创新，DA-Block=attention + selection，而多模态更需要“selection”，即那些模态对某些区域更有用，哪些模态里是噪声，因此可以考虑：
 - i. 跨模态的注意力：PAM是在单模态里做位置依赖，CAM是在单模态里做通道依赖，可以借鉴CoaT/MedFusionNet/SwinMultiModality几篇文章，把跨模态融进DA-Block和skip connection
 - ii. 多个DA block适配不同模态，并不是所有模态用同一个DA block，设计出 modality-aware DA block
 - b. 轻量化 / 小模型设计，减少DA-Block参数量，原文作者主要通过实验减少中间通道数到1/16，从而减少计算参数；而DA-Block的计算量主要是PAM和CAM的瓶颈：

$$O(H^2W^2C) + O(C^2HW)$$

还可以从以下方向优化：

- i. 注意力稀疏化，比如采取局部窗口注意力 Swin-Transformer，PAM里做的NxN全局注意力是最大开销，可以把图像分成MxM小window，只在window内做自注意力，则可优化为，M^2比较小可以近似为线性

$$O\left(\frac{HW}{M^2} \cdot M^4\right) = O(HWM^2)$$

一般的Swin优化都在vanilla的Transformer，很少专门针对DA-block做

- ii. 低秩分解：PAM里的NxN和CAM里的CxN都是计算量大瓶颈，而注意力矩阵往往是高度冗余的(即rank不高)，图片里patch很多相似，通道存在强相关，因此并不需要计算完整矩阵，只需要找2个小矩阵P属于NxR，Q属于RxN，则A约等于PQ，复杂度从O(N^2)→O(2NR)，有针对Transformer做低秩分解的如Linformer，但针对DA+图像分割做的很少

- iii. Group Attention: CAM里的CxC矩阵, 通道数越多计算量越大, 可以把通道分开若干组, 每组单独做attention, 再拼回去
- iv. 总结: 针对DA**可以对PAM用Swin+低秩分解, 对CAM用Group Attention**

Ref:

- 什么叫位置细节? 什么叫通道特征? 为什么Transformer不能的同时处理捕捉这两个?
 - 位置细节指不同位置像素之间的空间关系、形状、轮廓等, 如肿瘤边缘形状, 器官轮廓
 - 通道特征指不同feature map通道中学习到语义信息的差异和依赖关系
 - Transformer的本质是自注意力, 即把图像切成patch, 每个patch看做一个token, 自注意力计算主要建模patch level之间的关系, 即全局上下文很强, 但缺乏
 - 像素级别的空间位置关系
 - 通道间的依赖关系
- 双注意力机制指什么? 什么时候会用双注意力机制? 为什么作者会想到用双注意力机制去优化?
 - 双注意力机制指**空间维度(位置)的注意力(PAM)+通道维度的注意力(CAM)**
 - 正因为分析出来Transformer的自注意力缺乏这两种能力, 因此不如就在Transformer前后加PAM和CAM
- 为什么双注意力机制能提取医学图像特有的空间位置和通道特征? 为什么又能在跳跃链接中过滤冗余信息? 有什么公式或者定量的分析吗?

PAM 的公式:

$$S_{ji} = \frac{\exp(B_i \cdot C_j)}{\sum_{i=1}^N \exp(B_i \cdot C_j)}$$

- S_{ji} 表示位置 i 对位置 j 的影响
- 用每个位置之间的相似度做 softmax $\rightarrow$ 得到空间权重图
- 最终输出:

$$E_j = \alpha \sum_{i=1}^N S_{ji} D_i + A_j$$

$\rightarrow$ 保留了全局空间信息, 并融合原始局部特征。

所以:

PAM = “看所有像素与当前像素的关系, 把重要的位置信息保留下来。”

CAM 的公式:

$$X_{ji} = \frac{\exp(A_i \cdot A_j)}{\sum_{i=1}^C \exp(A_i \cdot A_j)}$$

- X_{ji} 表示通道 i 对通道 j 的影响
- 最终输出:

$$E_j = \beta \sum_{i=1}^C X_{ji} A_i + A_j$$

$\rightarrow$ 让网络学到:

“哪些通道是强相关的, 需要相互加强。”

传统 skip connection:

$$F_{\text{skip}} = F_{\text{encoder}}$$

$\rightarrow$ 无论信息是否重要, 全部传递给 decoder。

DA-Block 改成:

$$F'_{\text{skip}} = DA(F_{\text{encoder}})$$

在 DA 里:

- 弱相关的空间区域 $\rightarrow$ 注意力权重低
- 弱相关的通道 $\rightarrow$ 被抑制

所以:

DA-Block = 选择性保留 skip connection 里的有用信息。